


REȚEA DE RECONSTRUCȚIE INSPIRATĂ DE MODELUL FERESTREI DUBLE GLISANTE PENTRU DETECȚIA ANOMALIILOR

DIRECTNET

Slt. Ing. Denis-Liviu IANA
Slt. Ing. Denis-Georgian GURĂU

IPOTEZA ARTICOLULUI



Capabilitate

Permite discriminarea materialelor pe baza semnăturii spectrale/chimice unice (ex. diferențierea perfectă între elemente naturale și sintetice).



Specificul datelor

Imaginile hiperspectrale (HSI) sunt structurate ca un cub tridimensional, capturând informație pe sute de canale înguste și continue.

Obiectivul HAD (Hyperspectral Anomaly Detection)



Identificarea nesupravegheată a țintelor de dimensiuni reduse care deviază semnificativ de la tiparul statistic al fundalului înconjurător.

Autoencoderele convenționale eșuează în detecția anomaliilor deoarece, fiind prea puternice, funcționează ca un „xerox perfect” care reconstruiește fidel atât fundalul, cât și țintele, lăsând eroarea reziduală minimă peste tot și menținând anomaliile camuflate

CE SUNT ANOMALIILE?



„...obiecte care ocupă o suprafață extrem de mică și care, în același timp, deviază de la tiparul general (pattern-ul) al fundalului înconjurător.” („objects that occupy an extremely small area and deviate from the overall pattern of their surrounding background as well”).

COMPONENTELE METODEI

Reconstruction Error

Diferența matematică dintre pixelul original și pixelul prezis. Este instrumentul principal prin care generăm alarma de anomalie.

Unlabeled data

Imagini care nu au fost adnotate manual de om (nu știm dinainte unde sunt anomaliile).

Input image patch

O sub-imagine pătratică (de ex. 19 x 19 pixeli) decupată din imaginea mare, care este trimisă rețelei ca un pachet de date locale.

Inner window

Zona centrală din interiorul patch-ului unde informația este ștearsă intenționat (mascată). Este zona oarbă concepută pentru a ascunde corpul anomaliei.

Outer window

Regiunea rămasă la marginea patch-ului (în afara ferestrei). Este singura zonă pe care rețeaua o poate vedea și care conține exclusiv distribuția fundalului.

Adaptive depth

Capacitatea DirectNet de a-și schimba automat numărul de straturi (blocuri ResNet) în funcție de cât de mare sau mic este patch-ul ales, pentru a-și alinia perfect câmpul vizual cu datele.

PRIMA METODĂ DIN LITERATURĂ - DETECTORUL STATISTIC RX (REED-XIAOLI)

Ideea de bază presupune că fundalul imaginii (iarba, solul uniform) respectă o distribuție normală (o curbă Gauss)

Ce calculează algoritmul ? Cum funcționează detecția ? Regula de alarmare

O medie a fundalului pentru fiecare canal în parte
O matrice de covarianță, componentă esențială care mapează toate corelațiile și variațiile naturale din scenă.

Folosește Distanța Mahalanobis ca filtru pentru fiecare pixel
Scade media din pixelul testat și lasă matricea să comprime cele B canale într-un singur număr final.

Dacă un pixel se află la o distanță statistică uriașă de media fundalului, sistemul îl clasifică drept anomalie.

$$D^2 = (\mathbf{x} - \mathbf{m})^T \mathbf{C}^{-1} (\mathbf{x} - \mathbf{m})$$

where:

D^2 = Mahalanobis distance

$\mathbf{x}$ = Vector of data

$\mathbf{m}$ = Vector of mean values of independent variables

$\mathbf{C}^{-1}$ = Inverse Covariance matrix of independent variables

$\mathbf{T}$ = Indicates vector should be transposed

Problema cu Global RX

Analizează toată imaginea deodată
Contaminarea fundalului, dacă în scenă apar obiecte străine mari, ele strică media statistică, micșorează distanțele iar anomaliile devin greu de detectat

EVOLUȚIA ALGORITMULUI - LOCAL RX (LRX)

Introduce strategia de fereastră dublă glisantă (două pătrate concentrice în jurul pixelului testat).

Fereastră exterioară


Calculează media și covarianța strict pentru vecinii locali.

Fereastră interioară

Funcționează ca o barieră care blochează corpul anomaliei să se scurgă în calcule și să contamineze datele.

Dezavantaje

Cost computațional uriaș, este obligat să recalculeze de la zero matricea și inversa ei la fiecare pixel, prăbușindu-se ca viteză
Alarme false, greșește des atunci când fundalul local își schimbă brusc textura.



METODELE BAZATE PE REPREZENTARE LINIARĂ - SR ȘI CRD

$$w = (D^T D + \lambda I)^{-1} D^T y$$

$$\min_w \|y - Dw\|_2^2 + \lambda \|w\|_1$$

$$S = \|y - Dw_{\text{final}}\|_2^2$$

Schimbarea de paradigmă, se renunță la formulele de probabilitate. Pixelul testat este privit ca un puzzle matematic ce trebuie reconstruit din vecinii săi.

Strategia locală (Fereastra dublă glisantă)

1. Construirea dicționarului (D) – pixelii din fereastra exterioară sunt izolați și folosiți ca bază de date (piese de puzzle)
2. Sistemul de ecuații – se caută un set de ponderi (w) care, înmulțite cu dicționarul, să recreeze perfect pixelul central (y). Ecuația ideală $y = D \times w$.

Diferența dintre metode (Restricțiile impuse)

SR (Sparse Representation) – obligă algoritmul să folosească doar câțiva vecini selectați.

CRD (Collaborative Representation) – obligă toți vecinii să colaboreze și să își împartă ponderile uniform

Logica de detecție

Se calculează eroarea reziduală (Pixel real – Pixel reconstruit).

Eroare minimă – pixelul seamănă cu vecinii (fundal)

Eroare uriașă – pixelul nu poate fi replicat din mediu (**Anomalie**)

Complexitatea de calcul

Sparse este extrem de lentă, fiind imposibil de utilizat în timp real
Sparse este critic dependentă de Lambda. Un parametru reglat greșit distruge fie raritatea vectorului, fie a acuratețea reconstrucției.

Collaborative, risc de overfitting obligând toți vecinii să colaboreze, dacă o anomalie poluează dicționarul local, algoritmul o va camufla și va rata detecția.

REPREZENTAREA CU RANG MIC (LRR) - MODELUL GLOBAL

Ecuția de descompunere

Toată această metodă se bazează pe o singură împărțire simplă a imaginii globale (X)
L (Low-Rank) - reprezintă fundalul. Este o matrice compactă, deoarece elementele de fundal se repetă masiv în imagine.
S (Sparse) - reprezintă anomaliile (țintele căutate). Este o matrice aproape goală (plină de zerouri), în care doar pixelii rari și izolați au valori.

Cum funcționează algoritmul

Nu mai folosește ferestre glisante, algoritmul ia toată imaginea deodată.
Procesul de optimizare - algoritm iterativ care separă datele - filtrează tot ce este predictibil și trimite în L, tot ce rămâne pe dinafară ajunge în matricea de anomalii S

Generarea hărții de detecție

La final, pixelii care au supraviețuit în matricea rară S și au valori ridicate sunt extrași direct pentru a desena harta finală de detecție (anomaliile vor lumina alb în fundal negru).

Dezavantaje

Ipoteza de bază pică dacă anomaliile sunt mari, LRR funcționează perfect doar dacă anomaliile sunt foarte mici și izolate (pixeli singulari)
Deși LRR elimină ferestrele glisante (procesul local), ea procesează întreaga imagine hiperspectrală ca pe o singură matrice globală uriașă.

$$\min_{L,S} \|L\|_* + \lambda \|S\|_{2,1} \quad \text{astfel încât} \quad X = L + S$$

REȚEAUA NEURONALĂ DIRECTNET


Faza de antrenare (Self-supervised)

Se utilizează o rețea neuronală convoluțională profundă cu trei caracteristici esențiale

Blocuri ResConv (Reziduale Convoluționale) – extrag caracteristicile spațio-spectrale complexe și previn pierderea informației prin conexiuni de tip skip

Scalare adaptivă a adâncimii – rețeaua își ajustează automat numărul de straturi în funcție de dimensiunea patch-ului de input, corelând perfect câmpul receptiv cu datele

Mecanismul blind-block – o mască matematică șterge/maschează pixelii din fereastra interioară (inner window), făcându-i invizibili pentru rețea



Faza de detecție

Odată ce modelul s-a stabilizat, detecția se realizează instantaneu. Imaginea hiperspectrală brută trece prin întreaga rețea antrenată. Se calculează Eroarea Reziduală care măsoară cât de fidel a reușit rețeaua să replice imaginea originală (eroarea este minimă pe fundal și maximă pe anomalii).

Harta finală de detecție (D) este obținută direct prin calculul diferenței absolute dintre imaginea originală și cea construită.

FUNCȚIA DE PIERDERE

Formulele de mascare duală

Înainte de a calcula eroarea, algoritmul definește matematic cele două zone (fereastra interioară și exterioară) folosind măști binare. P_{bm} - masca pentru blocul orb, P_{om} - masca pentru context
 $P_{om} = 1 - P_{bm}$

Faza de detecție

Pentru a-și face upgrade la ponderi, rețeaua calculează eroarea dintre P_O (patch-ul original brut) și P_h (patch-ul reconstruit/prezis de rețea).

Explicația mecanismului

Calculul diferenței ($P_O - P_h$) - rețeaua scade pixel cu pixel imaginea generată din cea originală pentru a vedea unde a greșit

Înmulțirea cu masca exterioară - masca P_{om} are valoarea 0 în toată zona centrală (în Inner Window) toate erorile din centru dispar

Efectul asupra actualizării - când se aplică algoritmul de backpropagation, gradientul erorii pentru pixelii centrali devin exact 0. Prin urmare, rețeaua primește penalizări și își modifică ponderile doar pentru greșelile făcute în fereastra exterioară.

Varianta cu Norma ℓ_1 (Eroarea Absolută):

$$L_{\text{self}} = \|(P_o - P_h) \odot P_{\text{om}}\|_1$$

Varianta cu Norma ℓ_2 (Eroarea Pătratică):

$$L_{\text{self}} = \|(P_o - P_h) \odot P_{\text{om}}\|_2^2$$

METRICILE DE EVALUARE

Analiza Curbei ROC


Curba ROC (Receiver Operating Characteristic) măsoară capacitatea algoritmului de a separa anomaliile de fundal prin variația continuă a pragului r (0,1)

Axele graficului

Axa Y (P_d - True Positive Rate) - probabilitatea de detecție, ideal cât mai aproape de 1
Axa X (P_f - False Positive Rate) - rata de alarme false, ideal cât mai aproape de 0

Forma ideală

Un detector teoretic perfect va genera o curbă care urcă instantaneu pe axa Y de la 0,0 la colțul ideal 0,1 (100% detecție cu 0% alarme false), iar apoi evoluează pe plafonul graficului către punctul final 1,1 (pe măsură ce pragul r scade la 0)



PUNCTELE TARI / SLABE ALE METODEI

Avantaje majore

Modelare neliniară complexă - depășește limitările metodelor clasice (RX, SR, CRD) care presupun eronat un amestec spectral pur liniar. Straturile convoluționale adânci înțeleg fenomene complexe (reflexii multiple, umbre)

Învățare auto-supervizată (Self-Supervised) - optimizare hibridă (pierdere spațială - MSE + Unghi spectral SAM) extrage caracteristici profunde fără a necesita adnotări manuale (Ground Truth) în faza de antrenare

Eficiență computațională în detecție - elimină costul uriaș al ferestrelor glisante (LRX). Detecția se realizează instantaneu printr-o singură trecere (Forward Pass), maximizând indicatorul AUC.

Limitări tehnologice

Dependența critică de optimizare - necesită resurse hardware (GPU) și timp considerabil în faza inițială de antrenare a ponderilor, spre deosebire de formulele statistice directe (RX)

Sensibilitate la parametri - performanța este direct dependentă de reglajul fin al ratei de învățare (Learning Rate) și al coeficientului alpha (balanța SAM), existând risc de supra-învățare (Overfitting)

Risc de auto-contaminare spectrală - în scene hiperspectrale extrem de poluate sau cu anomalii masive, rețeaua tinde să asimileze greșit țintele ca fiind parte din fundal, reducând eroarea de reconstrucție în zonele critice.